Academia de Studii Economice București
Facultatea de Cibernetică, Statistică și Informatică Economică
Specializarea: Informatică Economică

Proiect pachete software

Profesori coordonatori:
Prof. univ. dr. Oprea Simona-Vasilica

Deaconu Beatrice-Elena
Deaconu Karina-Maria
Grupa 1088, seria C

București 2026

Conținut

1. INTRODUCERE **5**

2. ANALIZA DATELOR UTILIZÂND PYTHON **6**

2.1. ÎNCĂRCAREA ȘI EXPLORAREA INIȚIALĂ A DATELOR 6

2.1.1. Definirea problemei *6*
2.1.2. Informații necesare pentru rezolvare *6*
2.1.3. Metode de calcul și instrumente utilizate *6*
2.1.4. Prezentarea rezultatelor *6*
2.1.5. Interpretarea economică a rezultatelor *7*

2.2. PREPROCESAREA DATELOR ȘI CONVERSIA VARIABILELOR TEMPORALE 7

2.2.1. Definirea problemei *7*
2.2.2. Informații necesare pentru rezolvare *7*
2.2.3. Metode de calcul și transformări aplicate *8*
2.2.4. Prezentarea rezultatelor *8*
2.2.5. Interpretarea economică a rezultatelor *8*

2.3. TRATAREA VALORILOR LIPSĂ ȘI A VALORILOR EXTREME 8

2.3.1. Definirea problemei *8*
2.3.2. Informații necesare pentru rezolvare *8*
2.3.3. Metode de calcul și transformări aplicate *9*
2.3.4. Prezentarea rezultatelor *9*
2.3.5. Interpretarea economică a rezultatelor *11*

2.4. CODIFICAREA VARIABILELOR CATEGORICE 11

2.4.1. Definirea problemei *11*
2.4.2. Informații necesare pentru rezolvare *11*
2.4.3. Metode de calcul și transformări aplicate *11*
2.4.4. Prezentarea rezultatelor *11*
2.4.5. Interpretarea economică a rezultatelor *12*

2.5. SCALAREA VARIABILELOR NUMERICE 12

2.5.1. Definirea problemei *12*
2.5.2. Informații necesare pentru rezolvare *12*
2.5.3. Metode de scalare utilizate *12*
2.5.4. Prezentarea rezultatelor *12*
2.5.5. Interpretarea economică a rezultatelor *13*

2.6. ANALIZA STATISTICĂ ȘI AGREGAREA DATELOR 13

2.6.1. Definirea problemei *13*
2.6.2. Informații necesare pentru rezolvare *13*
2.6.3. Metode de grupare și agregare *13*
2.6.4. Prezentarea rezultatelor *14*
2.6.5. Interpretarea economică a rezultatelor *14*

2.7. VIZUALIZAREA DATELOR PRIN GRAFICE 14

2.7.1. Definirea problemei *14*
2.7.2. Informații necesare pentru rezolvare *15*
2.7.3. Metode de reprezentare grafică *15*
2.7.4. Prezentarea rezultatelor *15*
2.7.5. Interpretarea economică a rezultatelor *16*

2.8. ANALIZA VALORII MEDII A TRANZACȚIILOR PE INTERVALE DE VÂRSTĂ 16
2.8.1. Definirea problemei 16
2.8.2. Informații necesare pentru rezolvare 16
2.8.3. Metode de calcul și modele utilizate 17
2.8.4. Prezentarea rezultatelor 17
2.8.5. Interpretarea economică a rezultatelor 17
2.9. SEGMENTAREA CLIENȚILOR UTILIZÂND K-MEANS 18
2.9.1. Definirea problemei 18
2.9.2. Informații necesare pentru rezolvare 18
2.9.3. Metode de clusterizare utilizate 18
2.9.4. Prezentarea rezultatelor 18
2.9.5. Interpretarea economică a rezultatelor 19
2.10. REGRESIA LINIARĂ MULTIPLĂ CU STATSMODELS 19
2.10.1. Definirea problemei 19
2.10.2. Informații necesare pentru rezolvare 20
2.10.3. Metode de calcul și algoritmi utilizați 20
2.10.4. Prezentarea rezultatelor 20
2.10.5. Interpretarea economică a rezultatelor 20
3. ANALIZA DATELOR UTILIZÂND SAS 21
3.1. IMPORTUL ȘI CREAREA SETULUI DE DATE SAS 21
3.1.1. Definirea problemei 21
3.1.2. Informații necesare pentru rezolvare 21
3.1.3. Metode de import și creare a datelor 21
3.1.4. Prezentarea rezultatelor 22
3.1.5. Interpretarea economică a rezultatelor 22
3.2. DEFINIREA ȘI UTILIZAREA FORMATELOR PERSONALIZATE 22
3.2.1. Definirea problemei 22
3.2.2. Informații necesare pentru rezolvare 22
3.2.3. Metode de definire a formatelor 23
3.2.4. Prezentarea rezultatelor 23
3.2.5. Interpretarea economică a rezultatelor 24
3.3. PROCESAREA CONDIȚIONALĂ ȘI ITERATIVĂ A DATELOR 24
3.3.1. Definirea problemei 24
3.3.2. Informații necesare pentru rezolvare 24
3.3.3. Metode de procesare utilizate 24
3.3.4. Prezentarea rezultatelor 25
3.3.5. Interpretarea economică a rezultatelor 26
3.4. CREAREA ȘI ANALIZA SUBSETURILOR DE DATE 26
3.4.1. Definirea problemei 26
3.4.2. Informații necesare pentru rezolvare 26
3.4.3. Metode de selecție a datelor 26
3.4.4. Prezentarea rezultatelor 27
3.4.5. Interpretarea economică a rezultatelor 28
3.5. UTILIZAREA FUNCȚIILOR SAS PENTRU PRELUCRAREA DATELOR 28
3.5.1. Definirea problemei 28
3.5.2. Informații necesare pentru rezolvare 29
3.5.3. Funcții utilizate 29
3.5.4. Prezentarea rezultatelor 29
3.5.5. Interpretarea economică a rezultatelor 30

3.6. COMBINAREA SETURILOR DE DATE UTILIZÂND PROCEDURI SAS ȘI SQL 30
3.6.1. Definirea problemei 30
3.6.2. Informații necesare pentru rezolvare 30
3.6.3. Metode de combinare a datelor 31
3.6.4. Prezentarea rezultatelor 31
3.6.5. Interpretarea economică a rezultatelor 32
3.7. UTILIZAREA MASIVELOR PENTRU PRELUCRAREA VARIABILELOR 33
3.7.1. Definirea problemei 33
3.7.2. Informații necesare pentru rezolvare 33
3.7.3. Metode de utilizare a masivelor 33
3.7.4. Prezentarea rezultatelor 34
3.7.5. Interpretarea economică a rezultatelor 34
3.8. GENERAREA DE RAPOARTE UTILIZÂND PROCEDURI SAS 35
3.8.1. Definirea problemei 35
3.8.2. Informații necesare pentru rezolvare 35
3.8.3. Metode de raportare 35
3.8.4. Prezentarea rezultatelor 36
3.8.5. Interpretarea economică a rezultatelor 37
3.9. ANALIZA STATISTICĂ A DATELOR 38
3.9.1. Definirea problemei 38
3.9.2. Informații necesare pentru rezolvare 38
3.9.3. Metode statistice utilizate 38
3.9.4. Prezentarea rezultatelor 39
3.9.5. Interpretarea economică a rezultatelor 39
3.10. REPREZENTAREA GRAFICĂ A DATELOR 39
3.10.1. Definirea problemei 39
3.10.2. Informații necesare pentru rezolvare 39
3.10.3. Metode de reprezentare grafică 40
3.10.4. Prezentarea rezultatelor 40
3.10.5. Interpretarea economică a rezultatelor 43
4. CONCLUZII 43
5. BIBLIOGRAFIE 44

1. Introducere

În ultimii ani, comerțul online a cunoscut o dezvoltare foarte rapidă, iar companiile au început să se bazeze tot mai mult pe analiza datelor pentru a înțelege comportamentul clienților și pentru a lua decizii mai bune. În domeniul retailului, este foarte important să știi ce produse se vând, cine sunt clienții și cum evoluează vânzările în timp.

În cadrul acestui proiect ne-am propus să analizăm activitatea unei companii de retail, folosind un set de date preluat de pe platforma Kaggle. Setul de date ales conține informații despre tranzacțiile realizate de clienți și este potrivit pentru analiza vânzărilor și a comportamentului de consum.

Setul de date include următoarele variabile:

Transaction ID	identificator unic pentru fiecare tranzacție
Date	data la care a avut loc tranzacția
Customer ID	identificatorul clientului
Gender	genul clientului (Male/Female)
Age	vârsta clientului
Product Category	categoria produsului achiziționat (de exemplu: Electronics, Clothing, Beauty)
Quantity	numărul de produse cumpărate
Price per Unit	prețul unui produs
Total Amount	valoarea totală a tranzacției

Pe baza acestor date putem analiza diferite aspecte importante, cum ar fi preferințele clienților, categoriile de produse cele mai populare sau evoluția vânzărilor în timp.

Pentru realizarea analizei am folosit două pachete software studiate, Python și SAS. Cu ajutorul Python am realizat prelucrări ale datelor, reprezentări grafice și modele de analiză, iar cu SAS am efectuat prelucrări suplimentare, analize statistice și rapoarte.

Scopul proiectului este de a evidenția tipare relevante în date și de a oferi o interpretare economică a rezultatelor. Pe baza analizelor realizate, am încercat să identificăm posibile direcții de dezvoltare și extindere pentru companie, astfel încât aceasta să își poată îmbunătăți performanța.

2. Analiza datelor utilizând Python

2.1. Încărcarea și explorarea inițială a datelor

2.1.1. Definirea problemei

În această etapă am dorit să încărcăm setul de date în aplicație și să vedem cum arată. Înainte de orice analiză, este important să înțelegem cu ce lucrăm: câte înregistrări avem, ce coloane există și ce tipuri de date conțin acestea.

2.1.2. Informații necesare pentru rezolvare

Pentru această etapă am folosit fișierul retail_sales_dataset.csv, care conține informațiile despre tranzacțiile companiei de retail. Ca instrumente, am folosit biblioteca pandas pentru încărcarea datelor și biblioteca streamlit pentru afișarea lor într-o aplicație web interactivă.

2.1.3. Metode de calcul și instrumente utilizate

Am folosit funcția st.file_uploader() din Streamlit pentru a permite utilizatorului să încarce fișierul CSV. Apoi, cu funcția pd.read_csv() am citit datele într-un DataFrame. Pentru explorare am folosit metoda head() care afișează primele 5 înregistrări, atributul shape pentru numărul de linii și coloane și atributul columns pentru lista coloanelor.

2.1.4. Prezentarea rezultatelor

În aplicație se afișează primele 5 înregistrări, dimensiunea setului de date (1000 de tranzacții și 9 coloane) și lista variabilelor disponibile. Am observat că fișierul conține coloane numerice precum Age, Quantity, Price per Unit, Total Amount și coloane de tip text precum Gender și Product Category.

	Transaction ID	Date	Customer ID	Gender	Age	Product Category	Quantity	Price per Unit	Total Amount
0	1	2023-11-24	CUST001	Male	34	Beauty	3	50	150
1	2	2023-02-27	CUST002	Female	26	Clothing	2	500	1000
2	3	2023-01-13	CUST003	Male	50	Electronics	1	30	30
3	4	2023-05-21	CUST004	Male	37	Clothing	1	500	500
4	5	2023-05-06	CUST005	Male	30	Beauty	2	50	100

Dimensiunea setului de date

Numar linii: 1000, Numar coloane: 9

Denumirile coloanelor

```
[
  0 : "Transaction ID"
  1 : "Date"
  2 : "Customer ID"
  3 : "Gender"
  4 : "Age"
  5 : "Product Category"
  6 : "Quantity"
  7 : "Price per Unit"
  8 : "Total Amount"
]
```

2.1.5. Interpretarea economică a rezultatelor

Această etapă inițială este importantă pentru că ne permite să înțelegem structura datelor cu care lucrăm. Variabilele identificate, cum ar fi categoria produsului, cantitatea cumpărată sau valoarea tranzacției, sunt indicatori esențiali pentru analiza activității comerciale a companiei. Pe baza lor putem face mai târziu analize despre comportamentul clienților și performanța vânzărilor.

2.2. Preprocesarea datelor și conversia variabilelor temporale

2.2.1. Definirea problemei

Coloana Date din setul de date este inițial de tip text. Pentru a putea analiza evoluția vânzărilor în timp, trebuie să transformăm această coloană într-un format de tip dată calendaristică. Apoi vrem să extragem din fiecare dată anul și luna în coloane separate.

2.2.2. Informații necesare pentru rezolvare

Pentru această etapă am folosit coloana Date din setul de date. Am folosit funcționalitățile bibliotecii pandas pentru manipularea datelor calendaristice.

2.2.3. Metode de calcul și transformări aplicate

Am folosit funcția pd.to_datetime() care convertește valorile de tip text în obiecte de tip dată. Apoi am extras anul cu metoda dt.year și luna cu metoda dt.month, creând două coloane noi: Year și Month.

2.2.4. Prezentarea rezultatelor

În aplicație se afișează primele 5 înregistrări cu noile coloane Year și Month adăugate. Astfel se poate verifica că extragerea anului și lunii s-a făcut corect.

	Date	Year	Month
0	2023-11-24 00:00:00	2023	11
1	2023-02-27 00:00:00	2023	2
2	2023-01-13 00:00:00	2023	1
3	2023-05-21 00:00:00	2023	5
4	2023-05-06 00:00:00	2023	5

2.2.5. Interpretarea economică a rezultatelor

Separarea datei în an și lună permite analiza vânzărilor pe perioade. Compania poate identifica lunile cu vânzări ridicate sau scăzute și poate observa tendințele sezoniere. Aceste informații sunt utile pentru planificarea stocurilor, a campaniilor promoționale și a strategiilor de marketing.

2.3. Tratarea valorilor lipsă și a valorilor extreme

2.3.1. Definirea problemei

Valorile lipsă și valorile extreme pot influența puternic rezultatele analizei. O singură valoare anormală poate denatura mediile și statisticile. De aceea, înainte de a face analize trebuie să identificăm și să tratăm aceste situații.

2.3.2. Informații necesare pentru rezolvare

Am folosit întregul set de date. Pentru identificarea valorilor lipsă am folosit pandas, pentru vizualizare am folosit bibliotecile matplotlib și seaborn, iar pentru detectarea outlierilor am folosit funcția zscore din biblioteca scipy.stats.

2.3.3. Metode de calcul și transformări aplicate

Am folosit metoda isnull().sum() pentru a calcula numărul de valori lipsă pe fiecare coloană. Rezultatul e afisat sub forma unui table care arata cate valori lipsa exista in fiecare variabila.

Pentru tratarea valorilor lipsă, dacă apar, am completat coloanele numerice cu media valorilor existente, iar coloanele de tip text cu valoarea cea mai frecventă (modul). Pentru identificarea valorilor extreme am realizat un boxplot, care arată grafic distribuția valorilor și evidențiază punctele atipice. Am calculat apoi z-score-ul pentru fiecare valoare numerică și am eliminat înregistrările cu z-score peste 3 (deci aflate la mai mult de 3 deviații standard de medie).

2.3.4. Prezentarea rezultatelor

Tabelul arata că setul de date nu conține valori lipsă. Boxplot-ul a evidențiat existența unor valori extreme la coloanele Total Amount și Quantity. După aplicarea filtrului z-score, numărul de înregistrări a scăzut cu aproximativ câteva zeci, ceea ce indică prezența unor tranzacții atipice.

	0
Transaction ID	0
Date	0
Customer ID	0
Gender	0
Age	0
Product Category	0
Quantity	0
Price per Unit	0
Total Amount	0
Year	0
Month	0

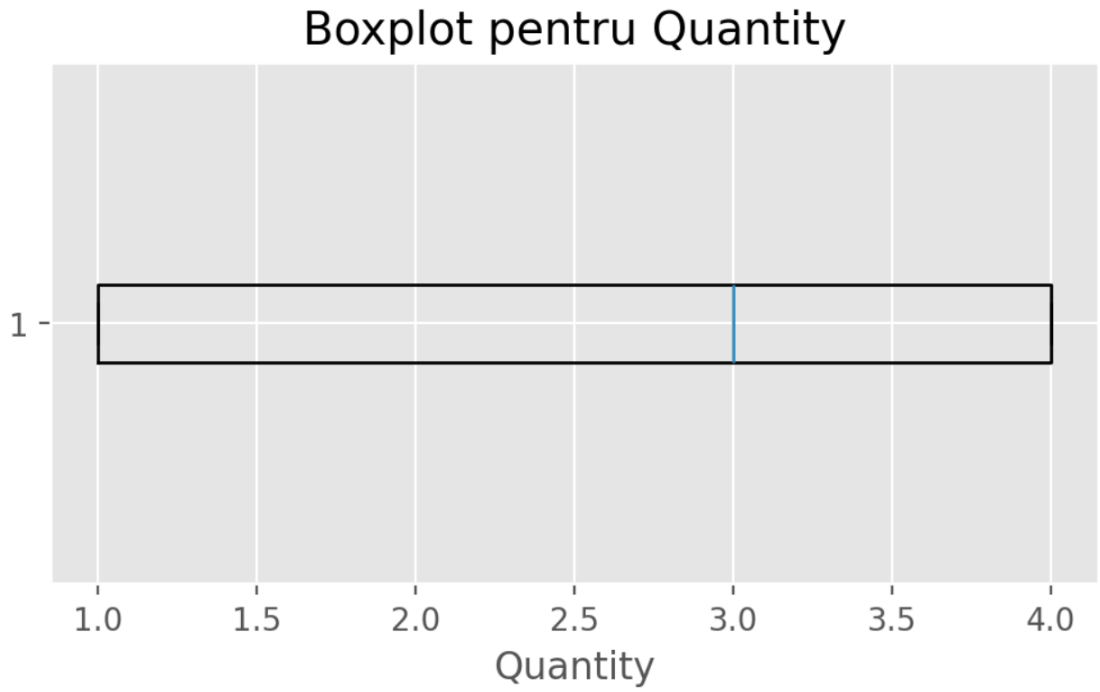

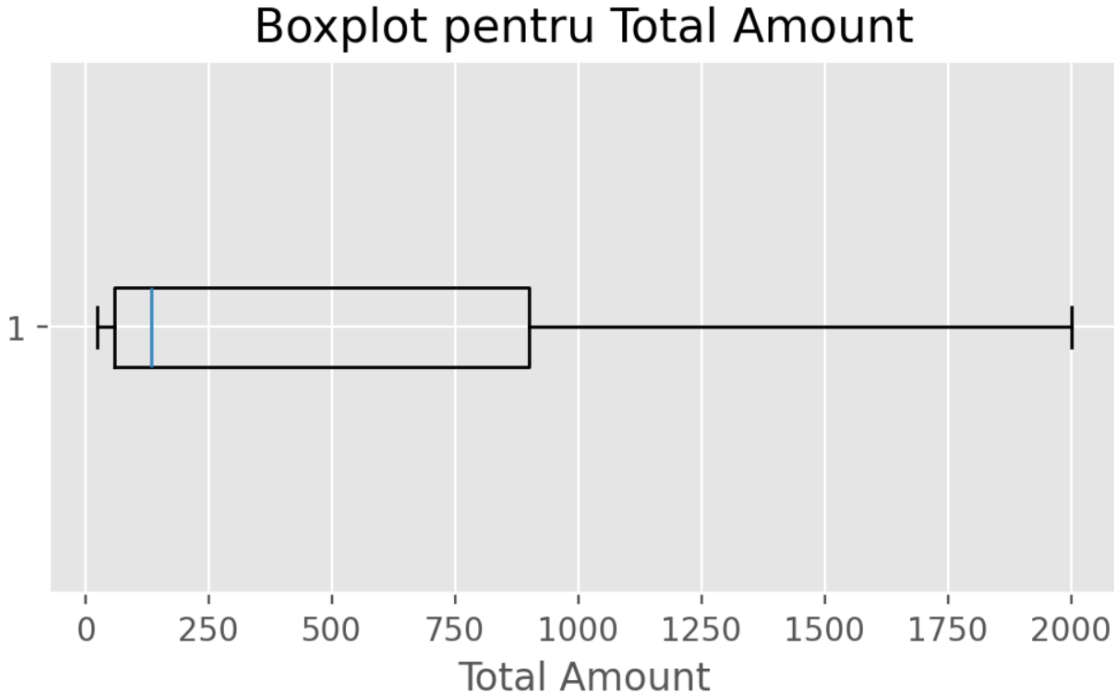

Numar inregistrari initial: 1000

Numar inregistrari dupa eliminarea outlierilor: 998

2.3.5. Interpretarea economică a rezultatelor

Faptul că nu avem valori lipsă arată că datele sunt complete și de bună calitate, putând fi folosite direct în analiză. Valorile extreme identificate prin boxplot pot reprezenta tranzacții mari făcute de clienți importanți sau achiziții în cantități mari. Aceste tranzacții pot fi tratate diferit de cele obișnuite, deoarece pot influența disproporționat statisticile generale.

2.4. Codificarea variabilelor categorice

2.4.1. Definirea problemei

În această etapă s-a urmărit transformarea variabilelor categorice în variabile numerice. Algoritmii de machine learning lucrează cu numere, nu cu text. De aceea, variabilele categorice ca Gender și Product Category trebuie transformate într-un format numeric înainte de a fi folosite în modele.

2.4.2. Informații necesare pentru rezolvare

Am folosit coloanele Gender și Product Category din setul de date. Am folosit clasa LabelEncoder din biblioteca scikit-learn pentru a face codificarea.

2.4.3. Metode de calcul și transformări aplicate

LabelEncoder atribuie un număr întreg unic fiecărei categorii distincte. De exemplu, pentru Gender, „Male" devine 1 și „Female" devine 0. Pentru Product Category, fiecare categorie (Beauty, Clothing, Electronics) primește un număr distinct (0, 1, 2). Am creat două coloane noi în setul de date: Gender_encoded și Product Category_encoded, păstrând și coloanele originale pentru a putea face comparația.

2.4.4. Prezentarea rezultatelor

În aplicație se afișează primele înregistrări cu coloanele inițiale și cele codificate alăturate, pentru a verifica corectitudinea transformării.

	Gender	Gender_encoded	Product Category	Product Category_encoded
0	Male	1	Beauty	0
1	Female	0	Clothing	1
2	Male	1	Electronics	2
3	Male	1	Clothing	1
4	Male	1	Beauty	0

2.4.5. Interpretarea economică a rezultatelor

Codificarea acestor variabile permite includerea informațiilor despre genul clienților și tipul produselor în modele predictive și analize statistice. Astfel, compania poate studia mai ușor cum influențează aceste caracteristici comportamentul de cumpărare și valoarea tranzacțiilor.

2.5. Scalarea variabilelor numerice

2.5.1. Definirea problemei

În această etapă s-a urmărit scalarea variabilelor numerice din setul de date, astfel încât acestea să poată fi comparate mai ușor și utilizate în modele statistice și predictive. Deoarece variabilele numerice au unități de măsură și intervale diferite, este necesară aducerea lor la o scară comună.

Variabilele numerice din setul de date au scări foarte diferite. De exemplu, Age are valori între 18 și 64, în timp ce Total Amount poate fi de mii de unități. Această diferență de scară poate face ca anumite variabile să influențeze disproporționat rezultatele modelelor. Pentru a evita asta, aducem toate variabilele la aceeași scară.

2.5.2. Informații necesare pentru rezolvare

Am folosit coloanele numerice Age, Quantity, Price per Unit și Total Amount. Pentru scalare am folosit clasa MinMaxScaler din biblioteca scikit-learn.

2.5.3. Metode de scalare utilizate

Metoda Min-Max Scaling transformă fiecare valoare astfel încât toate să se încadreze în intervalul 0-1. Formula folosită raportează diferența dintre valoarea curentă și valoarea minimă la diferența dintre valoarea maximă și cea minimă a coloanei. Astfel, valoarea minimă din coloană devine 0, valoarea maximă devine 1, iar restul valorilor sunt distribuite proporțional între ele.

2.5.4. Prezentarea rezultatelor

În aplicație se afișează două tabele alăturate: unul cu valorile originale și unul cu valorile scalate. Se observă cum, indiferent de scara inițială, toate valorile au fost aduse în intervalul 0-1, păstrând însă relațiile dintre observații.

Inainte de scalare:

	Age	Quantity	Price per Unit	Total Amount
0	34	3	50	150
1	26	2	500	1000
2	50	1	30	30
3	37	1	500	500
4	30	2	50	100

Dupa scalare (valori intre 0 si 1):

	Age	Quantity	Price per Unit	Total Amount
0	0.3478	0.6667	0.0526	0.0633
1	0.1739	0.3333	1	0.4937
2	0.6957	0	0.0105	0.0025
3	0.413	0	1	0.2405
4	0.2609	0.3333	0.0526	0.038

2.5.5. Interpretarea economică a rezultatelor

Scalarea nu schimbă semnificația economică a datelor, ci doar le face comparabile între ele. Această etapă este esențială pentru ca modelele de predicție și algoritmii de clusterizare să funcționeze corect. O variabilă cu valori mari nu va mai domina rezultatele, ci toate variabilele vor contribui în mod echilibrat la analiză.

2.6. Analiza statistică și agregarea datelor

2.6.1. Definirea problemei

Pentru a înțelege performanța vânzărilor, trebuie să calculăm indicatori agregați la nivel de categorie de produs sau grup de clienți. Astfel putem identifica ce categorii aduc cel mai mult venit și ce grupuri de clienți cheltuiesc mai mult.

2.6.2. Informații necesare pentru rezolvare

Am folosit coloanele Product Category, Gender, Total Amount și Quantity. Pentru gruparea și agregarea datelor am folosit funcțiile groupby() și pivot_table() din biblioteca pandas.

2.6.3. Metode de grupare și agregare

Funcția groupby() permite gruparea înregistrărilor după una sau mai multe variabile. Apoi, pentru fiecare grup se pot calcula indicatori statistici cu funcții ca sum (sumă), mean (medie) sau count (numărare). Am calculat valoarea totală a vânzărilor pentru fiecare categorie de produs și valoarea medie a tranzacțiilor pentru fiecare gen.

În plus, am folosit funcția pivot_table() pentru a crea un tabel încrucișat cu vânzările pe categorie și gen. Acest tabel permite o analiză bidimensională a datelor.

2.6.4. Prezentarea rezultatelor

În aplicație se afișează trei tabele: vânzările totale pe categorie, valoarea medie a tranzacțiilor pe gen și tabelul pivot care combină cele două perspective.

Vanzari totale pe categorie de produs

	Product Category	Total Amount
0	Beauty	143515
1	Clothing	155580
2	Electronics	156905

Valoarea medie a tranzactiilor pe gen

	Gender	Total Amount
0	Female	456.549
1	Male	455.4286

Tabel pivot: vanzari pe categorie si gen

	Product Category	Female	Male
0	Beauty	74830	68685
1	Clothing	81275	74305
2	Electronics	76735	80170

2.6.5. Interpretarea economică a rezultatelor

Aceste analize ajută compania să identifice categoriile de produse cele mai profitabile și să compare comportamentul de cumpărare între bărbați și femei. Tabelul pivot oferă o imagine completă, permițând observarea unor diferențe interesante, de exemplu dacă un anumit gen preferă o anumită categorie de produs. Pe baza acestor informații se pot ajusta strategiile de marketing și ofertele comerciale.

2.7. Vizualizarea datelor prin grafice

2.7.1. Definirea problemei

În această etapă s-a urmărit reprezentarea grafică a datelor pentru a evidenția mai clar relațiile și distribuțiile existente în setul de date. Vizualizarea datelor facilitează înțelegerea informațiilor și identificarea unor tipare relevante.

2.7.2. Informații necesare pentru rezolvare

Am folosit coloanele Product Category, Age, Quantity și Total Amount. Pentru realizarea graficelor am folosit bibliotecile matplotlib și seaborn, iar pentru afișarea lor în aplicație am folosit Streamlit.

2.7.3. Metode de reprezentare grafică

Am realizat doua tipuri de grafice. Un bar chart cu seaborn pentru a vizualiza vânzările totale pe fiecare categorie. O histogramă cu seaborn (cu linie KDE de densitate) pentru distribuția vârstei clienților.

2.7.4. Prezentarea rezultatelor

Bar chart-ul arată clar diferențele de vânzări între categorii și permite identificarea celei mai performante. Histograma vârstei arată cum sunt distribuiți clienții pe grupe de vârstă, evidențiind segmentele majoritare.

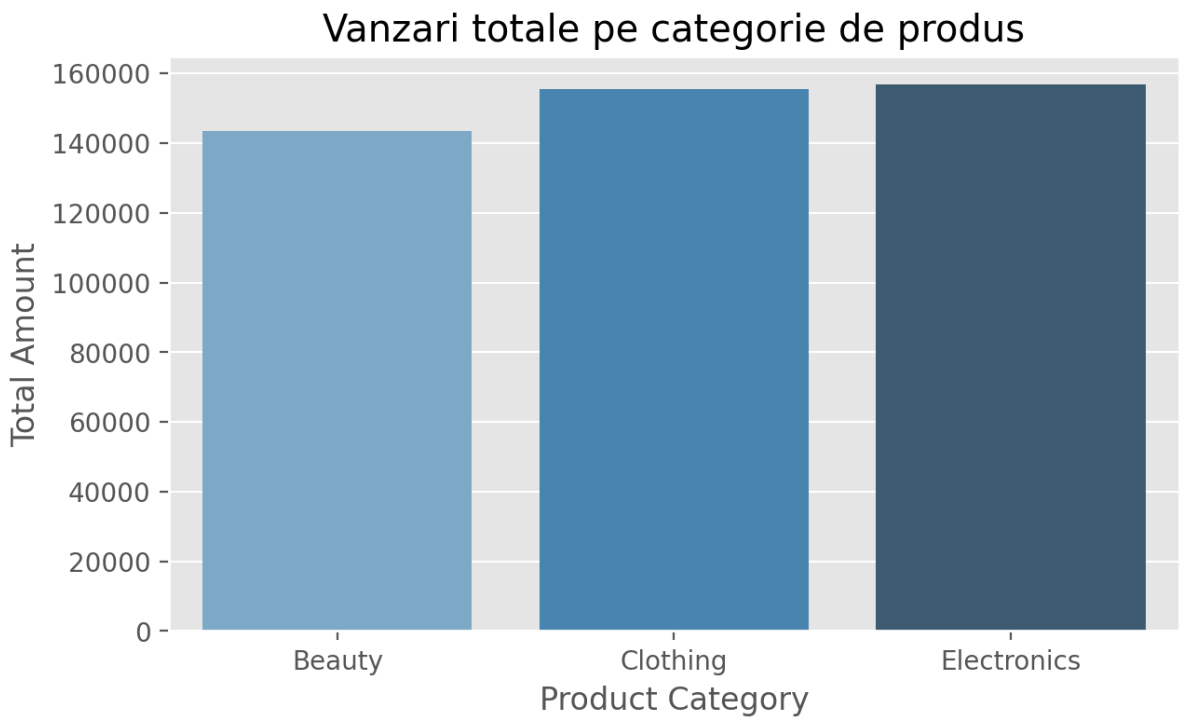

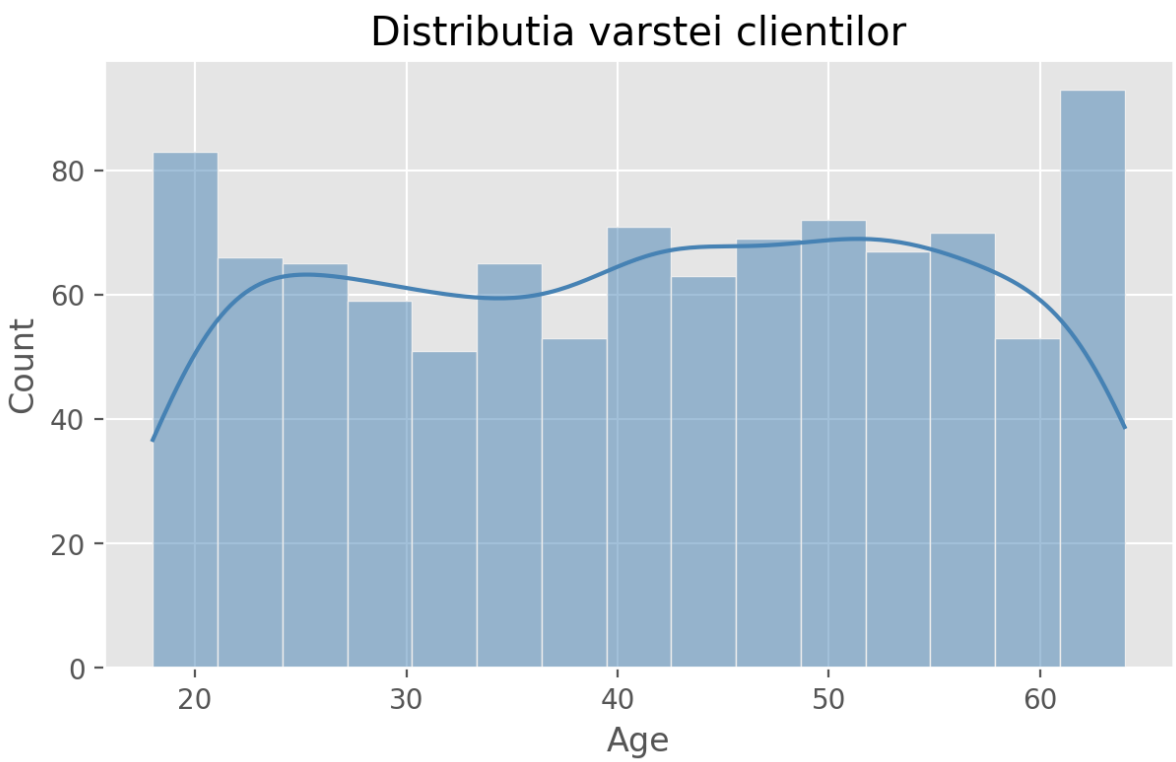

2.7.5. Interpretarea economică a rezultatelor

Graficele oferă o imagine vizuală foarte utilă pentru luarea deciziilor. Compania poate vedea rapid care sunt produsele cele mai vândute, care este vârsta tipică a clienților. Aceste informații sunt valoroase pentru planificarea ofertelor și pentru direcționarea campaniilor promoționale către segmentele potrivite.

2.8. Analiza valorii medii a tranzacțiilor pe intervale de vârstă

2.8.1. Definirea problemei

Diferite grupe de vârstă pot avea comportamente de consum diferite. Vrem să identificăm care grupă cheltuiește în medie cel mai mult per tranzacție, pentru a putea direcționa campaniile de marketing către segmentele potrivite.

2.8.2. Informații necesare pentru rezolvare

Am folosit coloanele Age și Total Amount din setul de date. Pentru gruparea pe intervale am folosit funcția cut() din pandas, iar pentru calculul mediilor am folosit groupby() și mean().

2.8.3. Metode de calcul și modele utilizate

Funcția cut() permite împărțirea unei variabile continue în intervale (bins). Am definit patru grupe de vârstă: 18-25, 26-35, 36-50 și 50+. Apoi, pentru fiecare grupă am calculat valoarea medie a tranzacțiilor cu groupby() combinat cu mean(). Rezultatele au fost vizualizate printr-un grafic bar chart pentru o comparație vizuală mai clară.

2.8.4. Prezentarea rezultatelor

În aplicație se afișează un tabel cu valoarea medie a tranzacțiilor pentru fiecare grupă de vârstă și un grafic bar chart corespunzător. Acesta permite observarea rapidă a diferențelor între grupe.

	Age Group	Total Amount
0	18-25	500.2959
1	26-35	480.3902
2	36-50	446.1981
3	50+	425.9105

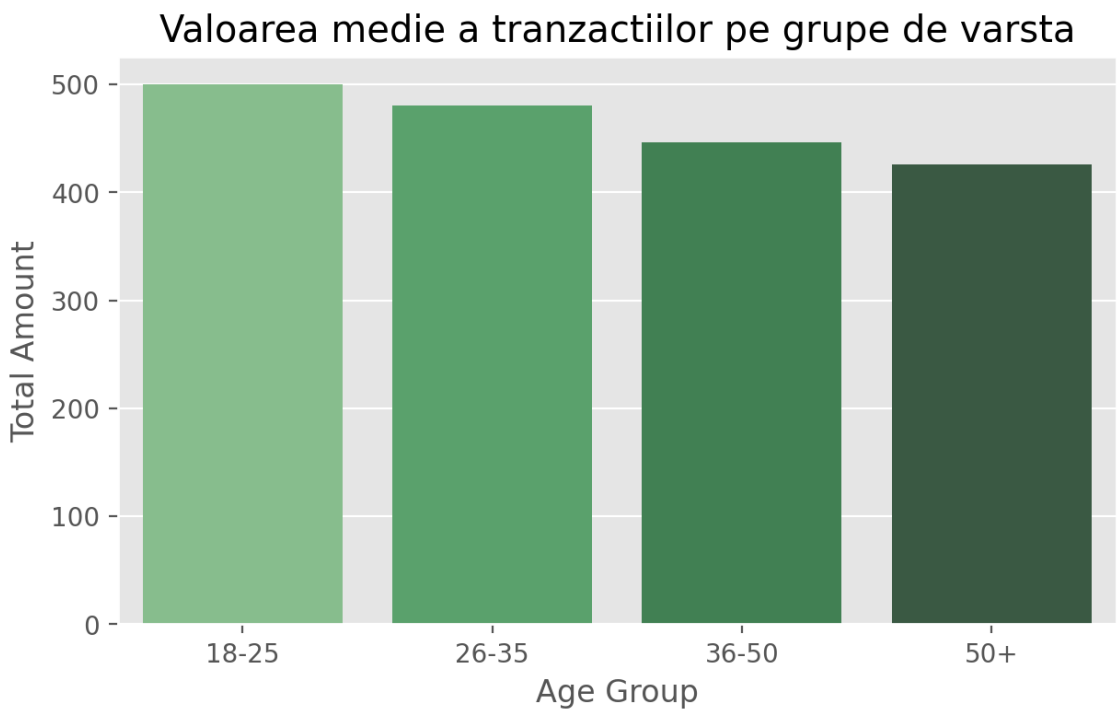

2.8.5. Interpretarea economică a rezultatelor

Analiza arată că anumite grupe de vârstă au tranzacții medii mai ridicate decât altele, ceea ce indică un comportament de consum mai intens. Aceste informații sunt valoroase pentru companie deoarece permit segmentarea ofertelor și a campaniilor promoționale. De exemplu,

dacă grupa 36-50 are tranzacții medii mai mari, compania poate dezvolta produse premium sau oferte personalizate pentru acest segment.

2.9. Segmentarea clienților utilizând K-Means

2.9.1. Definirea problemei

Vrem să grupăm clienții în segmente similare pe baza comportamentului lor de cumpărare. Această segmentare ne permite să identificăm tipuri distincte de clienți și să adaptăm strategiile pentru fiecare segment.

2.9.2. Informații necesare pentru rezolvare

Am folosit coloanele Age, Quantity și Total Amount din setul de date. Pentru aplicarea algoritmului de clusterizare am folosit clasa KMeans din scikit-learn, iar pentru scalare MinMaxScaler.

2.9.3. Metode de clusterizare utilizate

Algoritmul K-Means grupează observațiile în k clustere pe baza distanței față de centrul fiecărui grup (centroid). Înainte de aplicarea algoritmului am scalat datele cu MinMaxScaler, deoarece K-Means este sensibil la scara variabilelor. Am ales k=3 pentru a obține trei segmente distincte de clienți și am setat random_state=42 pentru a obține rezultate reproductibile.

2.9.4. Prezentarea rezultatelor

În aplicație se afișează numărul de clienți din fiecare cluster și valoarea medie a tranzacțiilor pe cluster. De asemenea, este generat un scatter plot care arată cum sunt poziționați clienții din fiecare cluster în funcție de cantitate și valoarea tranzacției.

Numar clienti pe clustere

	Cluster	Numar clienti
0	0	496
1	1	289
2	2	215

Valoarea medie a tranzactiilor pe cluster

	Cluster	Total Amount
0	0	253.7399
1	1	126.4533
2	2	1365.5814

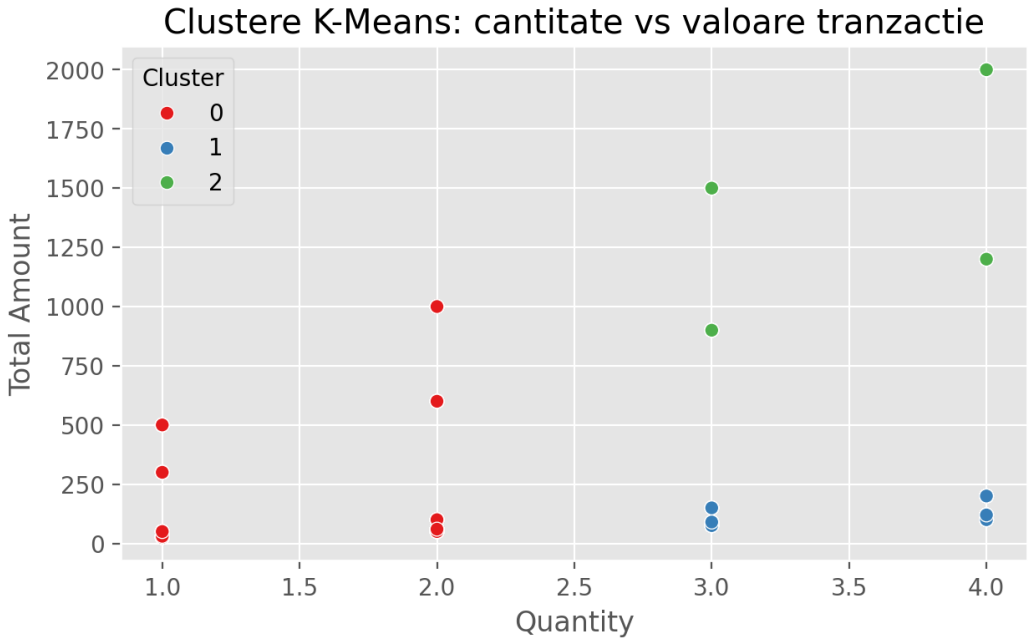

2.9.5. Interpretarea economică a rezultatelor

Cele trei clustere identificate reprezintă tipuri distincte de clienți. Clusterul cu valoarea medie cea mai ridicată reunește clienții valoroși, care generează cele mai mari venituri. Aceștia pot fi ținta unor strategii speciale de fidelizare. Clusterul cu valori medii reprezintă un segment stabil cu potențial de creștere, iar clusterul cu valori reduse poate fi vizat prin promoții pentru a crește valoarea coșului mediu de cumpărături. Această segmentare permite companiei să își optimizeze resursele de marketing, concentrând eforturile pe segmentele cu cel mai mare potențial.

2.10. Regresia liniară multiplă cu statsmodels

2.10.1. Definirea problemei

În această etapă am construit un model de regresie liniară care prezice valoarea totală a unei tranzacții pe baza vârstei clientului, cantității cumpărate și prețului unitar al produsului. Scopul a fost să identificăm cât de mult contribuie fiecare variabilă la valoarea finală a tranzacției.

2.10.2. Informații necesare pentru rezolvare

Am folosit variabilele Age, Quantity și Price per Unit ca variabile independente, iar Total Amount ca variabilă dependentă. Pentru construirea modelului am folosit biblioteca statsmodels.

2.10.3. Metode de calcul și algoritmi utilizați

Am folosit metoda celor mai mici pătrate (OLS) din biblioteca statsmodels, prin clasa OLS. Această metodă calculează automat coeficienții care minimizează diferența dintre valorile reale și cele prezise. Înainte de antrenare am adăugat o constantă cu funcția add_constant(), pentru a permite calculul interceptului. Apoi am extras coeficienții și valoarea R-pătrat care arată cât de bine se potrivește modelul cu datele.

2.10.4. Prezentarea rezultatelor

În aplicație se afișează un tabel cu coeficienții fiecărei variabile și valoarea R-pătrat. Coeficienții arată cu cât crește valoarea tranzacției la fiecare unitate suplimentară din variabila respectivă. R-pătrat indică procentul din variația valorii tranzacțiilor explicat de model.

Coeficientii modelului

	Variabila	Coeficient
0	const	-405.03
1	Age	-0.8
2	Quantity	177.21
3	Price per Unit	2.49

Performanta modelului

R^2 (cat din variatie explica modelul): 0.855

2.10.5. Interpretarea economică a rezultatelor

Modelul confirmă că valoarea tranzacției este determinată în principal de cantitatea cumpărată și de prețul unitar, în timp ce vârsta are un impact redus. Din punct de vedere economic, asta înseamnă că strategiile de creștere a vânzărilor trebuie să se concentreze pe stimularea cantităților achiziționate sau pe ajustarea prețurilor, nu pe targhetarea unor anumite grupuri de vârstă.

3. Analiza datelor utilizând SAS

3.1. Importul și crearea setului de date SAS

3.1.1. Definirea problemei

În această etapă s-a urmărit importul setului de date utilizat în proiect în mediul SAS și crearea unui set de date SAS care să poată fi utilizat în analizele ulterioare.

3.1.2. Informații necesare pentru rezolvare

Pentru realizarea acestei etape a fost utilizat fișierul retail_sales_dataset.csv, care conține informații despre tranzacțiile realizate într-o companie de retail. S-a folosit mediul SAS Studio și limbajul SAS pentru citirea și procesarea datelor.

3.1.3. Metode de import și creare a datelor

Importul datelor a fost realizat utilizând un pas de tip DATA, împreună cu instrucțiunea infile, care permite citirea datelor dintr-un fișier extern.

Opțiunea dsd a fost utilizată pentru a specifica faptul că datele sunt separate prin virgulă. De asemenea, opțiunea firstobs=2 a fost utilizată pentru a ignora prima linie din fișier, care conține denumirile coloanelor.

Variabilele au fost definite utilizând instrucțiunea input, specificând tipul acestora (numeric sau caracter). Pentru variabila Date s-a utilizat un format specific pentru date calendaristice.

```
data retail;
    infile '/home/u64484526/proiect_psw/retail_sales_dataset.csv' dsd firstobs=2;
    length Gender $ 10 Product_Category $ 20;
    input
        Transaction_ID
        Date : yymmdd10.
        Customer_ID $
        Gender $
        Age
        Product_Category $
        Quantity
        Price_per_Unit
        Total_Amount;
    format Date yymmdd10.;
run;

proc print data=retail (obs=10);
    title "Primele inregistrari din setul de date";
run;
```

3.1.4. Prezentarea rezultatelor

În urma rulării codului SAS a fost creat setul de date retail, care conține toate informațiile din fișierul CSV. Pentru verificarea corectitudinii importului au fost afișate primele înregistrări ale setului de date, utilizând procedura PROC PRINT.

Primele inregistrari din setul de date

Obs	Gender	Product_Category	Transaction_ID	Date	Customer_ID	Age	Quantity	Price_per_Unit	Total_Amount
1	Male	Beauty	1	2023-11-24	CUST001	34	3	50	150
2	Female	Clothing	2	2023-02-27	CUST002	26	2	500	1000
3	Male	Electronics	3	2023-01-13	CUST003	50	1	30	30
4	Male	Clothing	4	2023-05-21	CUST004	37	1	500	500
5	Male	Beauty	5	2023-05-06	CUST005	30	2	50	100
6	Female	Beauty	6	2023-04-25	CUST006	45	1	30	30
7	Male	Clothing	7	2023-03-13	CUST007	46	2	25	50
8	Male	Electronics	8	2023-02-22	CUST008	30	4	25	100
9	Male	Electronics	9	2023-12-13	CUST009	63	2	300	600
10	Female	Clothing	10	2023-10-07	CUST010	52	4	50	200

3.1.5. Interpretarea economică a rezultatelor

Importul corect al datelor reprezintă un pas esențial în procesul de analiză, deoarece permite utilizarea informațiilor într-un mediu de prelucrare statistică.

Setul de date creat conține informații relevante despre tranzacțiile realizate de clienți, care pot fi utilizate pentru analiza comportamentului de consum și a performanței vânzărilor.

3.2. Definirea și utilizarea formatelor personalizate

3.2.1. Definirea problemei

În această etapă s-a urmărit transformarea unor variabile numerice în formate mai ușor de interpretat, prin utilizarea formatelor personalizate. Scopul a fost obținerea unor categorii relevante din punct de vedere economic.

3.2.2. Informații necesare pentru rezolvare

Pentru realizarea acestei etape au fost utilizate variabilele Age și Total Amount din setul de date. S-a folosit limbajul SAS și procedura PROC FORMAT pentru definirea formatelor personalizate.

3.2.3. Metode de definire a formatelor

Formatele personalizate au fost definite utilizând procedura PROC FORMAT, care permite asocierea unor intervale de valori numerice cu etichete descriptive. Astfel, variabila Age a fost împărțită în grupe de vârstă, iar variabila Total Amount a fost clasificată în funcție de valoarea tranzacției. Ulterior, aceste formate au fost aplicate variabilelor corespunzătoare în cadrul unui nou set de date.

```
proc format;
    value varsta_fmt
        low -< 26 = "Tineri"
        26 -< 36 = "Adulti"
        36 -< 51 = "Maturi"
        51 - high = "Seniori";

    value valoare_fmt
        low -< 100 = "Scazuta"
        100 -< 500 = "Medie"
        500 - high = "Ridicata";
run;

data retail_formatat;
    set retail;

    format Age varsta_fmt.;
    format Total_Amount valoare_fmt.;
run;

proc print data=retail_formatat (obs=10);
    title "Date cu formate personalizate";
run;
```

3.2.4. Prezentarea rezultatelor

În urma aplicării formatelor personalizate, valorile numerice au fost înlocuite cu etichete descriptive, ceea ce a permis o interpretare mai ușoară a datelor.

Rezultatele au fost afișate sub formă de tabel, evidențiind noile categorii create.

Date cu formate personalizate									
Obs	Gender	Product_Category	Transaction_ID	Date	Customer_ID	Age	Quantity	Price_per_Unit	Total_Amount
1	Male	Beauty	1	2023-11-24	CUST001	Adulti	3	50	Medie
2	Female	Clothing	2	2023-02-27	CUST002	Adulti	2	500	Ridicata
3	Male	Electronics	3	2023-01-13	CUST003	Maturi	1	30	Scazuta
4	Male	Clothing	4	2023-05-21	CUST004	Maturi	1	500	Ridicata
5	Male	Beauty	5	2023-05-06	CUST005	Adulti	2	50	Medie
6	Female	Beauty	6	2023-04-25	CUST006	Maturi	1	30	Scazuta
7	Male	Clothing	7	2023-03-13	CUST007	Maturi	2	25	Scazuta
8	Male	Electronics	8	2023-02-22	CUST008	Adulti	4	25	Medie
9	Male	Electronics	9	2023-12-13	CUST009	Seniori	2	300	Ridicata
10	Female	Clothing	10	2023-10-07	CUST010	Seniori	4	50	Medie

3.2.5. Interpretarea economică a rezultatelor

Utilizarea formatelor personalizate permite gruparea clienților în funcție de vârstă și valoarea tranzacțiilor, facilitând analiza segmentelor de piață.

De exemplu, identificarea clienților care realizează tranzacții ridicate poate ajuta compania să dezvolte strategii de fidelizare, iar analiza pe grupe de vârstă permite adaptarea ofertelor în funcție de profilul consumatorilor.

3.3. Procesarea condițională și iterativă a datelor

3.3.1. Definirea problemei

În această etapă s-a urmărit procesarea condițională a datelor, prin crearea unor variabile noi pe baza unor reguli logice. Scopul a fost clasificarea clienților și a tranzacțiilor în categorii relevante pentru analiză.

3.3.2. Informații necesare pentru rezolvare

Pentru realizarea acestei etape au fost utilizate variabilele Age și Total Amount din setul de date retail. S-au folosit instrucțiuni de tip DATA STEP și expresii condiționale specifice limbajului SAS.

3.3.3. Metode de procesare utilizate

Procesarea datelor a fost realizată cu ajutorul instrucțiunilor condiționale IF, ELSE IF și THEN, care permit stabilirea unor reguli de clasificare. Pe baza valorilor variabilei Age a fost creată variabila Grupa_Varsta, iar pe baza valorilor variabilei Total_Amount a fost creată

variabila Nivel_Vanzare. Pentru variabilele noi de tip caracter a fost utilizată instrucțiunea LENGTH, astfel încât valorile text să fie stocate corect și să nu fie trunchiate.

```
data retail_conditional;
    set retail;
    length Grupa_Varsta $ 20;
    length Nivel_Vanzare $ 20;

    if Age <= 25 then
        Grupa_Varsta="Tineri";
    else if Age >= 26 and Age <= 35 then
        Grupa_Varsta="Adulti";
    else if Age >= 36 and Age <= 50 then
        Grupa_Varsta="Maturi";
    else if Age > 50 then
        Grupa_Varsta="Seniori";

    if Total_Amount < 100 then
        Nivel_Vanzare="Tranzactie mica";
    else if Total_Amount >= 100 and Total_Amount < 500 then
        Nivel_Vanzare="Tranzactie medie";
    else if Total_Amount >= 500 then
        Nivel_Vanzare="Tranzactie mare";
run;

proc print data=retail_conditional (obs=15);
    var Transaction_ID Customer_ID Gender Age Grupa_Varsta Total_Amount Nivel_Vanzare;
    title "Procesare conditionala si iterativa a datelor";
run;
```

3.3.4. Prezentarea rezultatelor

În urma aplicării regulilor condiționale, setul de date a fost completat cu două noi variabile: grupa de vârstă a clientului și nivelul valorii tranzacției.

Procesare conditionala si iterativa a datelor

Obs	Transaction_ID	Customer_ID	Gender	Age	Grupa_Varsta	Total_Amount	Nivel_Vanzare
1	1	CUST001	Male	34	Adulti	150	Tranzactie medie
2	2	CUST002	Female	26	Adulti	1000	Tranzactie mare
3	3	CUST003	Male	50	Maturi	30	Tranzactie mica
4	4	CUST004	Male	37	Maturi	500	Tranzactie mare
5	5	CUST005	Male	30	Adulti	100	Tranzactie medie
6	6	CUST006	Female	45	Maturi	30	Tranzactie mica
7	7	CUST007	Male	46	Maturi	50	Tranzactie mica
8	8	CUST008	Male	30	Adulti	100	Tranzactie medie
9	9	CUST009	Male	63	Seniori	600	Tranzactie mare
10	10	CUST010	Female	52	Seniori	200	Tranzactie medie
11	11	CUST011	Male	23	Tineri	100	Tranzactie medie
12	12	CUST012	Male	35	Adulti	75	Tranzactie mica
13	13	CUST013	Male	22	Tineri	1500	Tranzactie mare
14	14	CUST014	Male	64	Seniori	120	Tranzactie medie
15	15	CUST015	Female	42	Maturi	2000	Tranzactie mare

Rezultatele au fost afișate sub formă de tabel, permițând observarea modului în care fiecare client a fost încadrat într-o anumită categorie.

3.3.5. Interpretarea economică a rezultatelor

Clasificarea clienților pe grupe de vârstă și a tranzacțiilor pe niveluri de valoare permite o analiză mai clară a segmentelor de consum. Compania poate observa ce tipuri de clienți efectuează tranzacții mici, medii sau mari, ceea ce poate contribui la adaptarea strategiilor comerciale și de marketing. De asemenea, această etapă ajută la identificarea unor tipare de consum utile pentru dezvoltarea viitoare a activității firmei.

3.4. Crearea și analiza subseturilor de date

3.4.1. Definirea problemei

În această etapă s-a urmărit extragerea unor subseturi de date relevante din setul inițial, pe baza unor condiții specifice. Scopul a fost analiza unor segmente particulare de date, pentru a evidenția comportamente distincte ale clienților.

3.4.2. Informații necesare pentru rezolvare

Pentru realizarea acestei etape au fost utilizate variabilele Product Category și Total Amount din setul de date retail. S-au folosit instrucțiuni SAS de tip DATA STEP și condiții logice pentru selecția datelor.

3.4.3. Metode de selecție a datelor

Crearea subseturilor de date a fost realizată utilizând instrucțiunile WHERE și IF.

Instrucțiunea WHERE a fost utilizată pentru selectarea observațiilor care aparțin unei anumite categorii de produse, iar instrucțiunea IF a fost utilizată pentru filtrarea observațiilor în funcție de valoarea tranzacțiilor.

Astfel, au fost create două subseturi: unul care conține doar tranzacțiile din categoria Electronics și unul care conține doar tranzacțiile cu valori ridicate.

```
data electronics;
    set retail;
    where Product_Category="Electronics";
run;

data tranzactii_mari;
    set retail;

    if Total_Amount > 500;
run;

proc print data=electronics (obs=10);
    title "Clienti care au cumparat produse din categoria Electronics";
run;

proc print data=tranzactii_mari (obs=10);
    title "Clienti cu tranzactii mari";
run;
```

3.4.4. Prezentarea rezultatelor

Rezultatele au fost afișate sub formă de tabele, evidențiind observațiile selectate în funcție de criteriile definite. Subseturile create permit analiza separată a anumitor categorii de produse și a tranzacțiilor de valoare mare.

Clienti care au cumparat produse din categoria Electronics

Obs	Gender	Product_Category	Transaction_ID	Date	Customer_ID	Age	Quantity	Price_per_Unit	Total_Amount
1	Male	Electronics	3	2023-01-13	CUST003	50	1	30	30
2	Male	Electronics	8	2023-02-22	CUST008	30	4	25	100
3	Male	Electronics	9	2023-12-13	CUST009	63	2	300	600
4	Male	Electronics	13	2023-08-05	CUST013	22	3	500	1500
5	Female	Electronics	15	2023-01-16	CUST015	42	4	500	2000
6	Female	Electronics	18	2023-04-30	CUST018	47	2	25	50
7	Female	Electronics	26	2023-10-07	CUST026	28	2	500	1000
8	Female	Electronics	29	2023-08-18	CUST029	42	1	30	30
9	Male	Electronics	31	2023-05-23	CUST031	44	4	300	1200
10	Female	Electronics	33	2023-03-23	CUST033	50	2	50	100

Clienti cu tranzactii mari

Obs	Gender	Product_Category	Transaction_ID	Date	Customer_ID	Age	Quantity	Price_per_Unit	Total_Amount
1	Female	Clothing	2	2023-02-27	CUST002	26	2	500	1000
2	Male	Electronics	9	2023-12-13	CUST009	63	2	300	600
3	Male	Electronics	13	2023-08-05	CUST013	22	3	500	1500
4	Female	Electronics	15	2023-01-16	CUST015	42	4	500	2000
5	Male	Clothing	16	2023-02-17	CUST016	19	3	500	1500
6	Male	Clothing	20	2023-11-05	CUST020	22	3	300	900
7	Female	Electronics	26	2023-10-07	CUST026	28	2	500	1000
8	Female	Beauty	30	2023-10-29	CUST030	39	3	300	900
9	Male	Electronics	31	2023-05-23	CUST031	44	4	300	1200
10	Female	Beauty	35	2023-08-05	CUST035	58	3	300	900

3.4.5. Interpretarea economică a rezultatelor

Analiza subseturilor permite identificarea unor segmente relevante pentru companie. De exemplu, analiza produselor din categoria Electronics poate evidenția performanța acestui segment, iar analiza tranzacțiilor mari poate ajuta la identificarea clienților valoroși. Aceste informații pot fi utilizate pentru dezvoltarea strategiilor de marketing și pentru optimizarea ofertelor comerciale.

3.5. Utilizarea funcțiilor SAS pentru prelucrarea datelor

3.5.1. Definirea problemei

Pentru o analiză mai detaliată a datelor, a fost necesară prelucrarea variabilelor existente și obținerea unor informații suplimentare, cum ar fi componentele temporale și verificarea corectitudinii valorilor tranzacțiilor.

3.5.2. Informații necesare pentru rezolvare

Au fost utilizate variabilele Date, Quantity, Price per Unit și Total Amount. Pentru prelucrarea acestora s-au folosit funcții SAS specifice pentru manipularea datelor calendaristice și pentru realizarea de calcule numerice.

3.5.3. Funcții utilizate

Pentru extragerea informațiilor temporale s-au utilizat funcțiile MONTH() și YEAR(), care permit obținerea lunii și anului dintr-o variabilă de tip dată.

Pentru verificarea valorii tranzacțiilor s-a utilizat o expresie de calcul bazată pe variabilele Quantity și Price per Unit.

De asemenea, funcția ROUND() a fost utilizată pentru rotunjirea valorilor numerice, iar diferența dintre valorile calculate și cele existente a fost determinată pentru a evidenția eventuale abateri.

```
data retail_functii;
    set retail;
    length Luna 8 An 8;
    Luna=month(Date);
    An=year(Date);
    Total_Calculat=Quantity * Price_per_Unit;
    Diferenta=Total_Amount - Total_Calculat;
    Total_Rotunjit=round(Total_Amount, 0.01);
run;

proc print data=retail_functii (obs=15);
    var Transaction_ID Date Luna An Quantity Price_per_Unit Total_Amount
        Total_Calculat Diferenta Total_Rotunjit;
    title "Prelucrarea datelor utilizand functii SAS";
run;
```

3.5.4. Prezentarea rezultatelor

Rezultatele au evidențiat noile variabile create, respectiv luna și anul tranzacției, precum și valorile calculate și diferențele dintre acestea.

Tabelul rezultat permite observarea structurii temporale a datelor și verificarea corectitudinii valorilor tranzacțiilor.

Prelucrarea datelor utilizand functii SAS

Obs	Transaction_ID	Date	Luna	An	Quantity	Price_per_Unit	Total_Amount	Total_Calculat	Diferenta	Total_Rotunjit
1	1	2023-11-24	11	2023	3	50	150	150	0	150
2	2	2023-02-27	2	2023	2	500	1000	1000	0	1000
3	3	2023-01-13	1	2023	1	30	30	30	0	30
4	4	2023-05-21	5	2023	1	500	500	500	0	500
5	5	2023-05-06	5	2023	2	50	100	100	0	100
6	6	2023-04-25	4	2023	1	30	30	30	0	30
7	7	2023-03-13	3	2023	2	25	50	50	0	50
8	8	2023-02-22	2	2023	4	25	100	100	0	100
9	9	2023-12-13	12	2023	2	300	600	600	0	600
10	10	2023-10-07	10	2023	4	50	200	200	0	200
11	11	2023-02-14	2	2023	2	50	100	100	0	100
12	12	2023-10-30	10	2023	3	25	75	75	0	75
13	13	2023-08-05	8	2023	3	500	1500	1500	0	1500
14	14	2023-01-17	1	2023	4	30	120	120	0	120
15	15	2023-01-16	1	2023	4	500	2000	2000	0	2000

3.5.5. Interpretarea economică a rezultatelor

Extragerea lunii și anului din data tranzacției permite analiza evoluției vânzărilor în timp și identificarea unor eventuale tendințe sezoniere. Calculul valorii tranzacției pe baza cantității și a prețului unitar confirmă relația dintre variabile și poate evidenția eventuale erori sau inconsistențe în date. Rotunjirea valorilor facilitează interpretarea rezultatelor și prezentarea acestora într-un format mai clar.

3.6. Combinarea seturilor de date utilizând proceduri SAS și SQL

3.6.1. Definirea problemei

Pentru obținerea unei imagini mai complete asupra activității clienților, a fost necesară combinarea mai multor seturi de date derivate din baza inițială. Scopul a fost construirea unui tabel final care să reunească atât informațiile descriptive despre clienți, cât și indicatori agregați referitori la comportamentul lor de cumpărare.

3.6.2. Informații necesare pentru rezolvare

Au fost utilizate datele din setul retail, în special variabilele Customer_ID, Gender, Age, Transaction_ID, Quantity și Total_Amount. Pentru realizarea prelucrării s-au folosit proceduri SAS de sortare și proceduri SQL pentru agregare și combinare.

3.6.3. Metode de combinare a datelor

Mai întâi a fost creat un set de date care conține informații unice despre fiecare client, prin sortarea datelor și eliminarea duplicatelor pe baza variabilei Customer_ID.

Ulterior, prin intermediul procedurii PROC SQL, a fost construit un al doilea set de date, în care au fost calculați indicatori agregați pentru fiecare client: numărul tranzacțiilor, suma totală cheltuită, media valorii tranzacțiilor și numărul total de produse cumpărate.

În final, cele două seturi de date au fost combinate printr-o joncțiune de tip INNER JOIN, utilizând variabila comună Customer_ID.

```
proc sort data=retail out=clienti_info nodupkey;
    by Customer_ID;
run;

data clienti_info;
    set clienti_info;
    keep Customer_ID Gender Age;
run;

proc sql;
    create table totaluri_clienti as
    select Customer_ID,
        count(Transaction_ID) as Numar_Tranzactii,
        sum(Total_Amount) as Total_Cheltuit,
        mean(Total_Amount) as Medie_Tranzactie,
        sum(Quantity) as Total_Produse
    from retail
    group by Customer_ID;
quit;

proc sql;
    create table retail_clienti_final as
    select a.Customer_ID, a.Gender, a.Age, b.Numar_Tranzactii,
        b.Total_Cheltuit, b.Medie_Tranzactie, b.Total_Produse
    from clienti_info as a
    inner join totaluri_clienti as b
    on a.Customer_ID = b.Customer_ID;
quit;

proc print data=totaluri_clienti (obs=10);
    title "Indicatori agregati pe clienti";
run;
```

3.6.4. Prezentarea rezultatelor

În urma prelucrării au fost obținute două tabele relevante pentru analiză. Primul tabel conține indicatori agregați calculați pentru fiecare client, iar al doilea reprezintă tabelul final

combinat, care include atât informații descriptive despre client, cât și rezultatele agregate ale activității sale comerciale.

Rezultatele au fost afișate în SAS sub formă de rapoarte tabelare, permițând analiza rapidă a valorii totale cheltuite, a numărului de tranzacții și a cantității totale cumpărate de fiecare client.

Indicatori agregati pe clienti

Obs	Customer_ID	Numar_Tranzactii	Total_Cheltuit	Medie_Tranzactie	Total_Produse
1	CUST001	1	150	150	3
2	CUST002	1	1000	1000	2
3	CUST003	1	30	30	1
4	CUST004	1	500	500	1
5	CUST005	1	100	100	2
6	CUST006	1	30	30	1
7	CUST007	1	50	50	2
8	CUST008	1	100	100	4
9	CUST009	1	600	600	2
10	CUST010	1	200	200	4

Tabel final combinat

Obs	Customer_ID	Gender	Age	Numar_Tranzactii	Total_Cheltuit	Medie_Tranzactie	Total_Produse
1	CUST001	Male	34	1	150	150	3
2	CUST002	Female	26	1	1000	1000	2
3	CUST003	Male	50	1	30	30	1
4	CUST004	Male	37	1	500	500	1
5	CUST005	Male	30	1	100	100	2
6	CUST006	Female	45	1	30	30	1
7	CUST007	Male	46	1	50	50	2
8	CUST008	Male	30	1	100	100	4
9	CUST009	Male	63	1	600	600	2
10	CUST010	Female	52	1	200	200	4

3.6.5. Interpretarea economică a rezultatelor

Combinarea seturilor de date permite realizarea unei analize mai detaliate asupra comportamentului clienților. Astfel, compania poate identifica mai ușor clienții activi, clienții care generează venituri mari și segmentele care merită o atenție specială.

Aceste informații pot fi utilizate pentru strategii de fidelizare, oferte personalizate și campanii de marketing orientate către clienții cu valoare ridicată pentru companie.

3.7. Utilizarea masivelor pentru prelucrarea variabilelor

3.7.1. Definirea problemei

Pentru eficientizarea prelucrării datelor, a fost necesară utilizarea unor structuri care să permită aplicarea aceloraşi operații asupra mai multor variabile simultan.

3.7.2. Informații necesare pentru rezolvare

Au fost utilizate variabilele numerice Age, Quantity, Price per Unit și Total Amount din setul de date retail. Prelucrarea acestora a fost realizată utilizând structuri de tip array disponibile în limbajul SAS.

3.7.3. Metode de utilizare a masivelor

Pentru prelucrarea simultană a variabilelor numerice s-a utilizat o structură de tip ARRAY, care permite gruparea mai multor variabile într-o colecție accesibilă prin index. Parcurgerea elementelor array-ului a fost realizată utilizând o buclă de tip DO, care a permis aplicarea unor operații identice asupra fiecărei variabile. În cadrul procesării, valorile negative au fost corectate, iar pentru fiecare observație a fost calculată suma totală a variabilelor incluse în array.

```
data retail_array;
    set retail;
    array variabile[4] Age Quantity Price_per_Unit Total_Amount;
    Total_Suma=0;

    do i=1 to 4;

        if variabile[i] < 0 then
            variabile[i]=0;
        Total_Suma=Total_Suma + variabile[i];
    end;
    drop i;
run;

proc print data=retail_array (obs=15);
    var Transaction_ID Age Quantity Price_per_Unit Total_Amount Total_Suma;
    title "Prelucrarea variabilelor utilizand masive";
run;
```

3.7.4. Prezentarea rezultatelor

Rezultatul prelucrării a fost un nou set de date care conține o variabilă suplimentară, reprezentând suma valorilor analizate pentru fiecare observație.

Tabelul afișat evidențiază modul în care variabilele au fost procesate și valoarea totală obținută pentru fiecare tranzacție.

Prelucrarea variabilelor utilizand masive

Obs	Transaction_ID	Age	Quantity	Price_per_Unit	Total_Amount	Total_Suma
1	1	34	3	50	150	237
2	2	26	2	500	1000	1528
3	3	50	1	30	30	111
4	4	37	1	500	500	1038
5	5	30	2	50	100	182
6	6	45	1	30	30	106
7	7	46	2	25	50	123
8	8	30	4	25	100	159
9	9	63	2	300	600	965
10	10	52	4	50	200	306
11	11	23	2	50	100	175
12	12	35	3	25	75	138
13	13	22	3	500	1500	2025
14	14	64	4	30	120	218
15	15	42	4	500	2000	2546

3.7.5. Interpretarea economică a rezultatelor

Utilizarea masivelor permite prelucrarea eficientă a unui număr mare de variabile, ceea ce este util în analiza datelor economice.

Calculul unei sume agregate pe baza variabilelor numerice poate oferi o imagine generală asupra dimensiunii unei tranzacții și poate fi utilizat pentru comparații între clienți sau pentru identificarea unor tipare de consum.

3.8. Generarea de rapoarte utilizând proceduri SAS

3.8.1. Definirea problemei

Pentru analiza activității companiei a fost necesară realizarea unui raport detaliat al vânzărilor, care să permită observarea tranzacțiilor pe categorii de produse și calculul totalurilor corespunzătoare.

3.8.2. Informații necesare pentru rezolvare

Au fost utilizate variabilele Product_Category, Customer_ID, Transaction_ID, Gender, Age, Quantity, Price_per_Unit și Total_Amount din setul de date retail. Pentru generarea raportului s-au folosit procedurile SAS de sortare și raportare, în special PROC SORT și PROC PRINT.

3.8.3. Metode de raportare

Mai întâi, datele au fost sortate după categoria produsului, pentru a permite gruparea lor în raport. Ulterior, raportul a fost generat utilizând PROC PRINT, împreună cu opțiunile NOOBS și LABEL, pentru o afișare mai clară a informațiilor.

Declarația BY a fost utilizată pentru separarea raportului pe categorii de produse, declarația ID pentru evidențierea identificatorului clientului, iar declarația SUM pentru calculul subtotalurilor pe categorie și al totalului general. De asemenea, au fost definite etichete explicite pentru variabile și formate numerice pentru valorile monetare.

```
proc sort data=retail out=retail_raport;
    by Product_Category;
run;

proc print data=retail_raport noobs label sumlabel="Total categorie";
    by Product_Category;
    id Customer_ID;
    var Transaction_ID Gender Age Quantity Price_per_Unit Total_Amount;
    sum Quantity Total_Amount;
    label Transaction_ID="ID Tranzactie"
        Gender="Gen"
        Age="Varsta"
        Quantity="Cantitate"
        Price_per_Unit="Pret unitar"
        Total_Amount="Valoare tranzactie";
    format Price_per_Unit 8.2 Total_Amount 10.2;
    title "Raport detaliat al vanzarilor pe categorii de produse";
run;
```

3.8.4. Prezentarea rezultatelor

Rezultatul obținut a fost un raport detaliat al tranzacțiilor, organizat pe categorii de produse. Pentru fiecare categorie au fost afișate observațiile corespunzătoare, iar la finalul fiecărei secțiuni au fost calculate subtotalurile cantităților și ale valorii tranzacțiilor.

De asemenea, raportul include un total general, care oferă o imagine de ansamblu asupra valorii totale a vânzărilor și a cantității tranzacționate.

Table of Contents

- The Print Procedure
  - Product_Category=Beauty
    - Data Set WORK.RETAIL_RAPORT
  - Product_Category=Clothing
    - Data Set WORK.RETAIL_RAPORT
  - Product_Category=Electronics
    - Data Set WORK.RETAIL_RAPORT

Raport detaliat al vanzarilor pe categorii de produse

Product_Category=Beauty

Customer_ID	ID Tranzactie	Gen	Varsta	Cantitate	Pret unitar	Valoare tranzactie
CUST001	1	Male	34	3	50.00	150.00
CUST005	5	Male	30	2	50.00	100.00
CUST006	6	Female	45	1	30.00	30.00
CUST012	12	Male	35	3	25.00	75.00
CUST021	21	Female	50	1	500.00	500.00
CUST025	25	Female	64	1	50.00	50.00
CUST027	27	Female	38	2	25.00	50.00
CUST028	28	Female	43	1	500.00	500.00
CUST030	30	Female	39	3	300.00	900.00
CUST032	32	Male	30	3	30.00	90.00
CUST035	35	Female	58	3	300.00	900.00
CUST036	36	Male	52	3	300.00	900.00
CUST037	37	Female	18	3	25.00	75.00
CUST038	38	Male	38	4	50.00	200.00
CUST040	40	Male	45	1	50.00	50.00
CUST047	47	Female	40	3	500.00	1500.00

Table of Contents

- The Print Procedure
  - Product_Category=Beauty
    - Data Set WORK.RETAIL_RAPORT
  - Product_Category=Clothing
    - Data Set WORK.RETAIL_RAPORT
  - Product_Category=Electronics
    - Data Set WORK.RETAIL_RAPORT

CUST957	957	Female	60	4	30.00	120.00
CUST958	958	Male	62	2	25.00	50.00
CUST959	959	Female	42	2	30.00	60.00
CUST966	966	Male	60	2	500.00	1000.00
CUST970	970	Male	59	4	500.00	2000.00
CUST971	971	Female	27	4	50.00	200.00
CUST977	977	Female	35	3	25.00	75.00
CUST980	980	Female	31	3	25.00	75.00
CUST981	981	Female	30	2	30.00	60.00
CUST985	985	Female	19	2	25.00	50.00
CUST989	989	Female	44	1	25.00	25.00
CUST992	992	Female	57	2	30.00	60.00
CUST993	993	Female	48	3	50.00	150.00
CUST999	999	Female	36	3	50.00	150.00
CUST1000	1000	Male	47	4	30.00	120.00
Total categorie				849		156905.00
				2514		456000.00

3.8.5. Interpretarea economică a rezultatelor

Raportarea detaliată pe categorii de produse permite companiei să observe contribuția fiecărui segment la volumul total al vânzărilor. Subtotalurile pe categorii oferă informații utile pentru evaluarea performanței fiecărei linii de produse, iar totalul general permite aprecierea dimensiunii activității comerciale.

Un astfel de raport ajută la luarea deciziilor privind prioritățile de vânzare, gestionarea stocurilor și analiza profitabilității produselor.

3.9. Analiza statistică a datelor

3.9.1. Definirea problemei

Pentru înțelegerea mai aprofundată a structurii datelor, a fost necesară realizarea unei analize statistice descriptive. Scopul a fost evidențierea principalilor indicatori statistici pentru variabilele numerice și compararea acestora între categoriile de produse.

3.9.2. Informații necesare pentru rezolvare

Au fost utilizate variabilele numerice Age, Quantity, Price_per_Unit și Total_Amount din setul de date retail, precum și variabila Product_Category pentru gruparea observațiilor. Pentru prelucrare s-au folosit procedurile PROC SORT, PROC UNIVARIATE și PROC PRINT.

3.9.3. Metode statistice utilizate

Datele au fost sortate în funcție de categoria produsului, pentru a permite analiza separată pe grupuri. Ulterior, a fost utilizată procedura PROC UNIVARIATE pentru calcularea unor indicatori statistici descriptivi asupra variabilelor numerice.

Prin instrucțiunea OUTPUT s-a creat un nou set de date care conține, pentru fiecare categorie de produs, valorile medii, abaterile standard, valorile minime, maxime și medianele variabilelor analizate.

```
proc sort data=retail out=retail_stat;
    by Product_Category;
run;

proc univariate data=retail_stat noprint;
    by Product_Category;
    var Age Quantity Price_per_Unit Total_Amount;
    output out=statistici_retail
        mean=Medie_Age Medie_Quantity Medie_Price Medie_Total
        std=Std_Age Std_Quantity Std_Price Std_Total
        min=Min_Age Min_Quantity Min_Price Min_Total
        max=Max_Age Max_Quantity Max_Price Max_Total
        median=Mediana_Age Mediana_Quantity Mediana_Price Mediana_Total;
run;

proc print data=statistici_retail noobs label;
    title "Analiza statistica a datelor pe categorii de produse";
run;
```

3.9.4. Prezentarea rezultatelor

Rezultatul obținut a fost un tabel statistic agregat, în care sunt prezentate valorile principalilor indicatori descriptivi pentru fiecare categorie de produs.

Tabelul evidențiază diferențele dintre categorii în ceea ce privește vârsta clienților, cantitatea cumpărată, prețul unitar și valoarea totală a tranzacțiilor.

Analiza statistica a datelor pe categorii de produse

Product_Category	the mean, Age	the mean, Quantity	the mean, Price_per_Unit	the mean, Total_Amount	the standard deviation, Age	the standard deviation, Quantity	the standard deviation, Price_per_Unit	the standard deviation, Total_Amount	the largest value, Age	the largest value, Quantity	the largest value, Price_per_Unit	the largest value, Total_Amount	the median, Age	the median, Quantity	the median, Price_per_Unit	the median, Total_Amount	the smallest value, Age	the smallest value, Quantity	the smallest value, Price_per_Unit	the smallest value, Total_Amount
Beauty	40.3713	2.51140	184.055	467.476	13.8898	1.10067	194.929	563.613	64	4	500	2000	41	3	50	120	18	1	25	25
Clothing	41.9487	2.54701	174.288	443.248	13.4983	1.14265	186.017	550.696	64	4	500	2000	42	3	50	120	18	1	25	25
Electronics	41.7368	2.48246	181.901	458.787	13.6696	1.15308	189.050	567.540	64	4	500	2000	42	2	50	150	18	1	25	25

3.9.5. Interpretarea economică a rezultatelor

Analiza statistică permite observarea caracteristicilor principale ale tranzacțiilor și compararea categoriilor de produse din punct de vedere al comportamentului de cumpărare.

Valorile medii și medianele oferă informații despre nivelul obișnuit al tranzacțiilor, în timp ce valorile minime și maxime evidențiază variația acestora. Abaterea standard arată gradul de dispersie al datelor, fiind utilă pentru evaluarea stabilității comportamentului de consum în cadrul fiecărei categorii.

Aceste informații pot sprijini compania în analiza performanței comerciale și în adaptarea strategiilor de preț și vânzare.

3.10. Reprezentarea grafică a datelor

3.10.1. Definirea problemei

Pentru o înțelegere mai clară a structurii datelor, a fost necesară reprezentarea grafică a unor variabile numerice relevante. Scopul a fost evidențierea distribuției valorilor și identificarea eventualelor observații extreme.

3.10.2. Informații necesare pentru rezolvare

Au fost utilizate variabilele numerice Total_Amount și Quantity din setul de date retail. Pentru realizarea reprezentărilor grafice s-a folosit procedura PROC UNIVARIATE, împreună cu opțiunile HISTOGRAM și PLOT, conform stilului de lucru din seminar.

3.10.3. Metode de reprezentare grafică

Reprezentarea grafică a datelor a fost realizată utilizând procedura PROC UNIVARIATE. Pentru variabilele Total_Amount și Quantity s-au generat histograme, care permit observarea distribuției valorilor.

Pentru variabila Total_Amount a fost utilizată și opțiunea PLOT, care generează reprezentări grafice suplimentare, inclusiv box plot, utile pentru identificarea dispersiei datelor și a valorilor extreme. În plus, prin declarația ID au fost indicate observațiile prin identificatorul clientului.

```
proc univariate data=retail noprint;
    var Total_Amount;
    histogram Total_Amount;
    title "Histograma valorii totale a tranzactiilor";
run;

proc univariate data=retail noprint;
    var Quantity;
    histogram Quantity;
    title "Histograma cantitatii de produse cumparate";
run;

proc univariate data=retail plot;
    var Total_Amount;
    id Customer_ID;
    title "Box plot si analiza valorilor extreme pentru Total Amount";
run;
```

3.10.4. Prezentarea rezultatelor

Au fost obținute două histograme și un box plot. Histogramele evidențiază modul de distribuție al valorii totale a tranzacțiilor și al cantității de produse cumpărate, iar box plot-ul evidențiază dispersia datelor și eventualele valori extreme pentru Total_Amount.

Rezultatele grafice permit observarea rapidă a structurii datelor și completează analiza statistică realizată anterior.

Histograma valorii totale a tranzactiilor

The UNIVARIATE Procedure

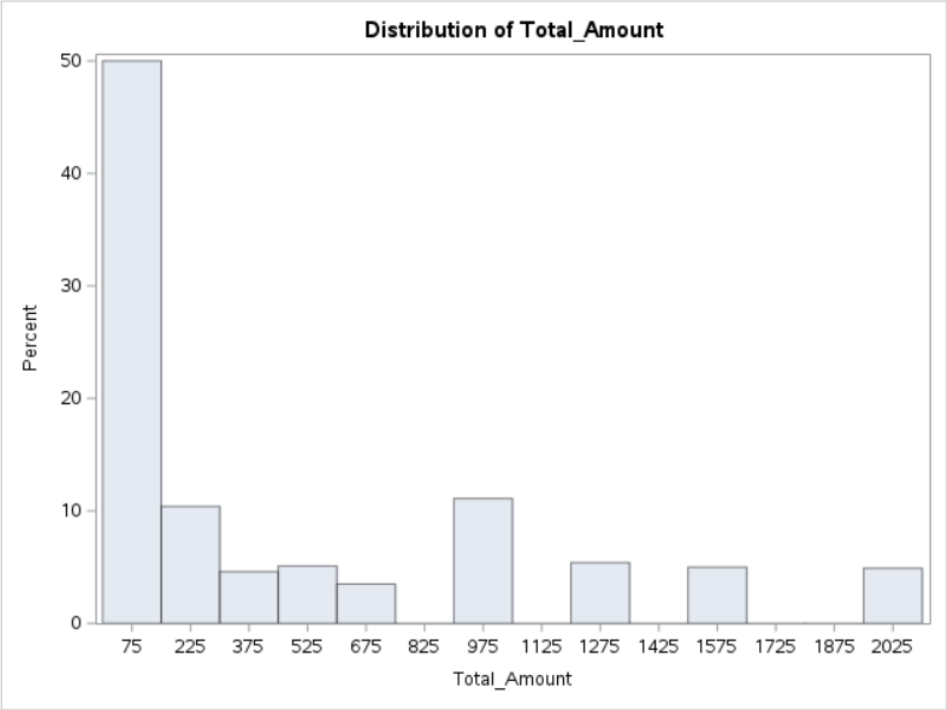

Histograma cantitatii de produse cumparate

The UNIVARIATE Procedure

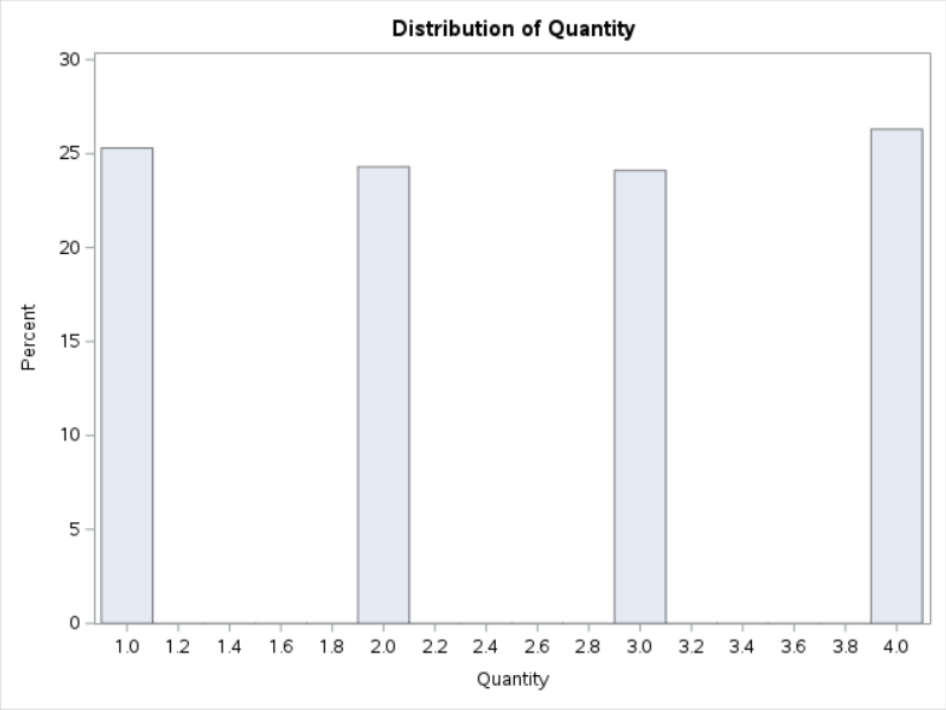

Box plot si analiza valorilor extreme pentru Total Amount

The UNIVARIATE Procedure
Variable: Total_Amount

Moments			
N	1000	Sum Weights	1000
Mean	456	Sum Observations	456000
Std Deviation	559.997632	Variance	313597.347
Skewness	1.37612824	Kurtosis	0.81503135
Uncorrected SS	521219750	Corrected SS	313283750
Coeff Variation	122.806498	Std Error Mean	17.70868

Basic Statistical Measures			
Location		Variability	
Mean	456.0000	Std Deviation	559.99763
Median	135.0000	Variance	313597
Mode	50.0000	Range	1975
		Interquartile Range	840.00000

Tests for Location: Mu0=0				
Test	Statistic		p Value	
Student's t	t	25.75008	Pr > |t|	<.0001
Sign	M	500	Pr >= |M|	<.0001
Signed Rank	S	250250	Pr >= |S|	<.0001

Quantiles (Definition 5)	
Level	Quantile
100% Max	2000
99%	2000
95%	1500
90%	1200
75% Q3	900
50% Median	135
25% Q1	60
10%	30
5%	25
1%	25
0% Min	25

Extreme Observations					
Lowest			Highest		
Value	Customer_ID	Obs	Value	Customer_ID	Obs
25	CUST989	989	2000	CUST832	832
25	CUST979	979	2000	CUST875	875
25	CUST967	967	2000	CUST927	927
25	CUST955	955	2000	CUST946	946
25	CUST952	952	2000	CUST970	970

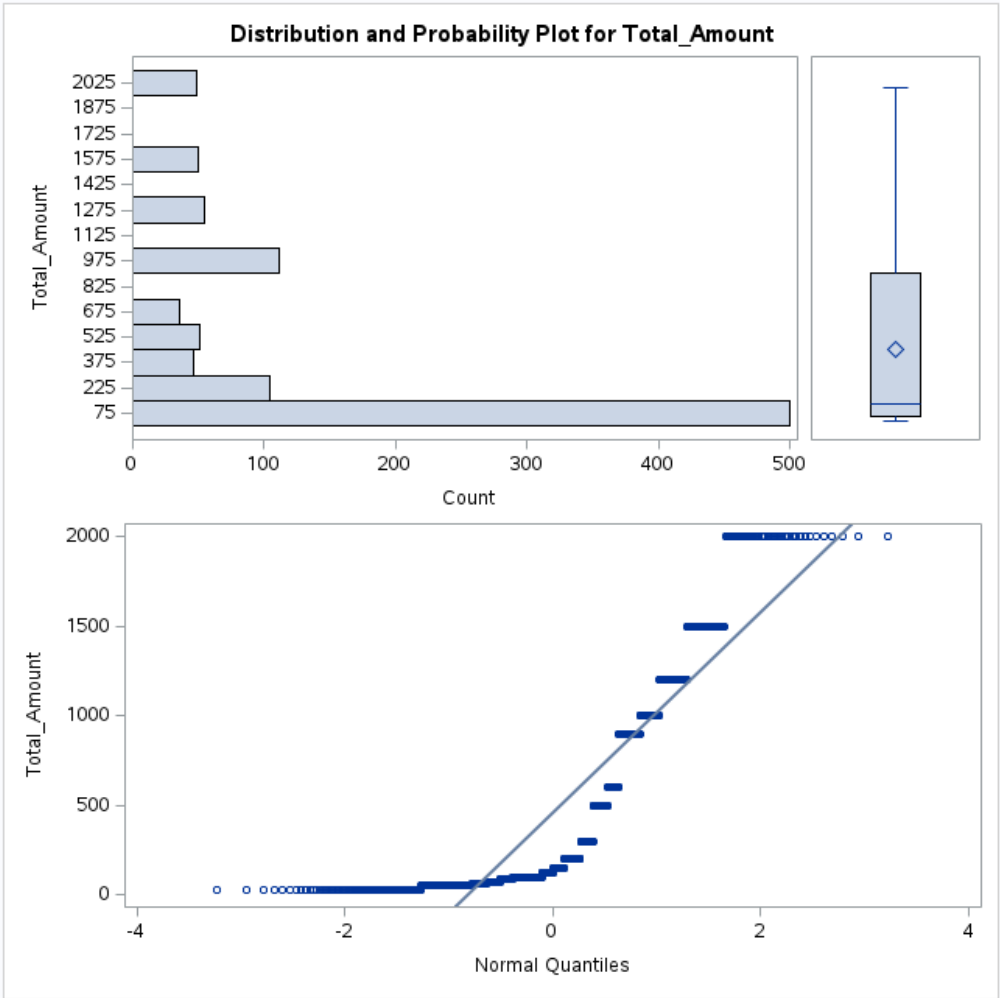

3.10.5. Interpretarea economică a rezultatelor

Histograma valorii totale a tranzacțiilor oferă informații despre frecvența diferitelor niveluri de cheltuieli și permite observarea intervalelor în care se concentrează majoritatea cumpărăturilor.

Histograma cantității cumpărate evidențiază comportamentul obișnuit al clienților în ceea ce privește numărul de produse achiziționate. Box plot-ul pentru Total_Amount ajută la identificarea tranzacțiilor neobișnuit de mari, care pot indica existența unor clienți importanți sau a unor cumpărături atipice.

Aceste reprezentări grafice contribuie la o mai bună înțelegere a comportamentului de consum și pot sprijini compania în fundamentarea unor decizii comerciale și promoționale.

4. Concluzii

Proiectul realizat a avut ca obiectiv analiza unui set de date privind tranzacțiile din domeniul retail, utilizând atât limbajul Python, cât și mediul SAS. Prin aplicarea metodelor de prelucrare, analiză și vizualizare a datelor, au fost obținute informații relevante despre comportamentul de cumpărare al clienților.

În cadrul analizei realizate în Python, s-au efectuat etape de explorare a datelor, curățare și preprocesare, codificare și scalare a variabilelor, precum și analize statistice și vizualizări grafice. De asemenea, au fost identificate relații între variabile și au fost realizate segmentări ale clienților, evidențiind factori importanți care influențează valoarea tranzacțiilor.

Partea de analiză realizată în SAS a permis aprofundarea prelucrării datelor prin utilizarea instrucțiunilor specifice limbajului, precum DATA STEP, proceduri de tip PROC și interogări SQL. Au fost definite formate personalizate, au fost realizate prelucrări condiționale, subseturi de date, combinări de seturi de date și analize statistice. De asemenea, au fost generate rapoarte și reprezentări grafice, care au oferit o imagine clară asupra structurii datelor.

Rezultatele obținute au evidențiat importanța variabilelor precum cantitatea și prețul unitar în determinarea valorii tranzacțiilor, precum și existența unor diferențe între categoriile de produse și segmentele de clienți. Analiza a permis identificarea unor tipare de consum și a unor segmente relevante pentru companie.

În concluzie, utilizarea combinată a instrumentelor Python și SAS a oferit o perspectivă completă asupra datelor analizate, contribuind la o mai bună înțelegere a fenomenelor economice și la fundamentarea unor decizii informate în domeniul retail.

5. Bibliografie

Retail Sales Dataset Dataset: Retail Sales Dataset, disponibil pe Kaggle: The World's AI Proving Ground